

LAPORAN AKHIR
PROYEK PENGANTI UAS

Mata Kuliah Kecerdasan Buatan
Semester Genap 2025/2026

**Klasifikasi Sentimen Ulasan Spotify Menggunakan
IndoBERT Berbasis Transformer**

Subjudul: Analisis Sentimen Teks Bahasa Indonesia / IndoBERT (Transformer)

Disusun oleh:

Dhafin Hamizan Setiawan	NPM. 2306267145
Daffa Bagus Dhiananto	NPM. 2306250756
Dimas Ananda Sutiardi	NPM. 2306250586
Rafi Naufal Aryaputra	NPM. 2306250680

Dosen Pengampu:

Muhammad Firdaus Syawaludin Lubis,
S.T., M.T., Ph.D.

DEPARTEMEN TEKNIK KOMPUTER
FAKULTAS TEKNIK
UNIVERSITAS INDONESIA

Mei 2026

LEMBAR PERNYATAAN ORISINALITAS

Kami yang bertandatangan di bawah ini menyatakan bahwa laporan ini, beserta seluruh isinya (termasuk Sub-bab IV.x masing-masing anggota dan berkas `metadata.json` yang merupakan bagian tidak terpisahkan), adalah hasil karya kelompok kami sendiri. Setiap kutipan, kode, atau gambar yang berasal dari sumber lain telah disitasi dengan benar. Penggunaan AI *assistant* telah dideklarasikan secara jujur pada Sub-bab IV.x.2.

Dhafin Hamizan Setiawan
NPM. [2306267145]



Dimas Ananda Sutiardi
NPM. [2306250586]



Daffa Bagus Dhiananto
NPM. [2306250756]



Rafi Naufal Aryaputra
NPM. [2306250680]



DAFTAR ISI

Lembar Pernyataan Orisinalitas	1
Abstrak	6
1 PENDAHULUAN & DEFINISI MASALAH	7
1.1 Topik yang Dipilih.....	7
1.2 Rumusan Masalah.....	7
1.3 Tujuan Proyek.....	8
1.4 Ruang Lingkup & Batasan.....	8
2 PENDEKATAN AI	9
2.1 Tinjauan Pustaka (<i>Related Work</i>).....	9
2.2 Landasan Teori Model yang Dipilih.....	10
2.3 Justifikasi Ilmiah Pemilihan Pendekatan AI.....	11
2.4 <i>Block Diagram</i> Sistem End-to-End.....	12
2.5 <i>Flowchart</i> Program.....	13
3 IMPLEMENTASI & HASIL EKSPERIMEN	14
3.1 Dataset & Pra-pemrosesan.....	14
3.2 Konfigurasi Eksperimen.....	15
3.3 Metrik Evaluasi.....	14
3.4 Hasil Kuantitatif.....	16
3.5 Analisis <i>Hyperparameter Tuning</i>	16
3.6 Hasil Kualitatif & <i>Error Analysis</i>	18
3.7 Pembahasan.....	20
4 PEMBAGIAN TUGAS & DEKLARASI KONTRIBUSI INDIVIDUAL	22
4.1 Dhafin Hamizan Setiawan – NPM. 2306267145.....	22
4.2 Dimas Ananda Sutiardi – NPM. 2306250586.....	23
4.3 Daffa Bagus Dhiananto – NPM. 2306250756.....	23
4.4 Rafi Naufal Aryaputra – NPM. 2306250680.....	24

5 KESIMPULAN & PEKERJAAN LANJUTAN	26
5.1 Kesimpulan.....	26
5.2 Klaim Bonus Skor.....	26
5.3 Pekerjaan Lanjutan (<i>Future Work</i>).....	27
A Berkas Metadata Proyek (JSON)	29
B Tautan Repositori & Dataset	33
C Research Participation Consent Form (<i>Informed Consent</i>)	34

DAFTAR GAMBAR

2.1	Arsitektur Transformer (Sumber: [1])	10
2.2	Block diagram sistem yang diusulkan	12
2.3	Flowchart program training dan inference	13
3.1	Perbandingan performa semua model (Accuracy & F1-Macro)	17
3.2	Confusion matrix Baseline TF-IDF + Logistic Regression	19
3.3	Confusion matrix IndoBERT terbaik (LR=2e-5, Epoch=3)	19
3.4	Distribusi sentimen dataset Spotify Reviews Indonesia	20

DAFTAR TABEL

2.1	Ringkasan tinjauan pustaka	9
3.1	Pembagian dataset	15
3.2	Hyperparameter eksperimen	15
3.3	Hasil kuantitatif model	16

ABSTRAK

Klasifikasi sentimen pada ulasan pengguna berbahasa Indonesia merupakan salah satu tantangan utama dalam implementasi model Transformer karena maraknya penggunaan bahasa informal, slang, dan konteks budaya yang khas. Penelitian ini menerapkan fine-tuning pada model IndoBERT yang berbasis arsitektur Transformer untuk mengklasifikasikan sentimen ulasan aplikasi Spotify pada Google Play Store ke dalam tiga kelas: negatif, netral, dan positif. Dataset yang digunakan adalah Spotify Reviews Indonesia (Google Play Store) dari Kaggle, yang berisi 100.000 ulasan pengguna dalam bahasa Indonesia dengan kolom Ulasan dan Rating. Label sentimen diturunkan secara otomatis dari nilai rating pengguna: rating 1–2 dipetakan sebagai negatif, rating 3 sebagai netral, dan rating 4–5 sebagai positif.

Setelah preprocessing berupa pembersihan teks ringan, dilakukan balanced sampling sebanyak 4.000 data per kelas (total 12.000 sampel) dan pembagian data 70/15/15 (training: 8.400, validasi: 1.800, test: 1.800). Sebagai baseline, digunakan TF-IDF dengan fitur unigram-bigram (max 10.000 fitur) yang dikombinasikan dengan Logistic Regression, menghasilkan akurasi 65,5% dan F1-Macro 65,09% pada test set. Model Transformer utama IndoBERT (indobenchmark/indobert-base-p1) di-fine-tune dengan learning rate 2×10^{-5} , batch size 8, dan 3 epoch, menghasilkan akurasi 67,89% dan F1-Macro 67,59% pada test set melampaui baseline sebesar 2,39 poin persentase pada akurasi dan 2,5 poin pada F1-Macro.

Eksperimen tuning dengan learning rate 1×10^{-5} menghasilkan akurasi 67,94% dan F1-Macro 67,58%, sedikit di bawah konfigurasi utama. Error analysis menunjukkan kelas netral paling sulit diklasifikasikan ($F1 = 0,50$), terutama karena ulasan netral seringkali mengandung campuran penilaian positif dan negatif atau teks yang sangat singkat. Hasil ini menunjukkan bahwa pendekatan berbasis arsitektur Transformer lewat IndoBERT secara konsisten mengungguli metode ekstraksi fitur statistik klasik untuk analisis sentimen teks berbahasa Indonesia.

Kata kunci: analisis sentimen, IndoBERT, Transformer, ulasan aplikasi, bahasa Indonesia

BAB 1

PENDAHULUAN & DEFINISI MASALAH

1.1 Topik yang Dipilih

Topik yang dipilih berfokus pada implementasi arsitektur Transformer, khususnya untuk menangani tugas analisis sentimen (sentiment analysis) pada teks berbahasa Indonesia. Topik ini dipilih karena ketiga anggota tim memiliki ketertarikan mendalam serta latar belakang di bidang pemodelan berbasis Transformer dan machine learning berbasis deep learning.

Ketersediaan dataset ulasan pengguna Spotify dalam bahasa Indonesia dari Kaggle yang berjumlah 100.000 entri menjadikan eksplorasi arsitektur ini sangat relevan dan praktis untuk dikembangkan. Selain itu, analisis sentimen berbasis Transformer pada ulasan aplikasi memiliki urgensi nyata di industri teknologi memberikan umpan balik otomatis yang presisi untuk membantu pengembang memahami pengalaman pengguna secara cepat dan terukur. Model berbasis Transformer seperti IndoBERT telah terbukti jauh lebih superior dalam menangani karakteristik teks berbahasa Indonesia dibandingkan pendekatan klasik, sehingga menjadikannya pilihan paling tepat sebagai pilar utama proyek ini.

1.2 Rumusan Masalah

- RM1.** Sejauh mana model IndoBERT berbasis Transformer mampu mengklasifikasikan sentimen ulasan aplikasi Spotify berbahasa Indonesia ke dalam tiga kelas (negatif, netral, positif) dibandingkan baseline TF-IDF + Logistic Regression?
- RM2.** Bagaimana pengaruh perbedaan learning rate ($2e-5$ vs $1e-5$) terhadap performa fine-tuning IndoBERT pada dataset ulasan Spotify Indonesia yang seimbang?
- RM3.** Kelas sentimen manakah yang paling sulit diprediksi oleh model IndoBERT, dan apa penyebab utama kesalahan prediksi tersebut?

1.3 Tujuan Proyek

- T1. Menerapkan fine-tuning model IndoBERT (indobenchmark/indobert-base-p1) pada dataset ulasan Spotify berbahasa Indonesia untuk klasifikasi sentimen tiga kelas.
- T2. Mengevaluasi dan membandingkan performa IndoBERT dengan baseline TF-IDF + Logistic Regression menggunakan metrik Accuracy dan F1-Macro.
- T3. Membandingkan dua konfigurasi hyperparameter IndoBERT (learning rate $2e-5$ dan $1e-5$) untuk mengidentifikasi konfigurasi optimal dalam konteks dataset ini.
- T4. Menganalisis pola kesalahan prediksi model terbaik guna mengidentifikasi keterbatasan model dan arah pengembangan lebih lanjut.

1.4 Ruang Lingkup & Batasan

Proyek ini berfokus pada domain ulasan aplikasi Spotify berbahasa Indonesia yang diambil dari Google Play Store. Varian model yang dievaluasi adalah IndoBERT base (indobenchmark/indobert-base-p1) sebagai model utama dan TF-IDF + Logistic Regression sebagai baseline. Metrik yang dievaluasi meliputi Accuracy, F1-Macro, Precision-Macro, dan Recall-Macro. Dataset yang digunakan adalah subset balanced 3.000 sampel (1.000 per kelas) dari 100.000 ulasan yang tersedia.

Hal-hal yang TIDAK dikerjakan dalam proyek ini: (1) tidak melakukan tuning arsitektur IndoBERT secara layer-by-layer; (2) tidak mengevaluasi pada data out-of-distribution (misalnya ulasan aplikasi lain atau domain berbeda); (3) tidak menggunakan teknik data augmentation pada teks; (4) tidak membandingkan dengan model Transformer lain seperti XLM-RoBERTa atau mBERT; (5) tidak melakukan deployment model ke production environment; (6) tidak menggunakan label sentimen yang dianotasi secara manual oleh manusia, seluruh label diturunkan dari nilai rating pengguna.

BAB 2

PENDEKATAN AI

2.1 Tinjauan Pustaka (*Related Work*)

Referensi dalam proyek kali ini ditunjukkan pada Tabel 2.1

Tabel 2.1: Ringkasan tinjauan pustaka

Penulis (Th.)	Metode	Dataset	Hasil	Keterbatasan
Devlin et al. (2019)	BERT: Pre-training of Deep Bidirectional Transformers	GLUE, SQuAD, dll.	SOTA di 11 NLP tasks	Hanya bahasa Inggris; biaya komputasi tinggi
Wilie et al. (2020)	IndoBERT: pre-trained BERT untuk Bahasa Indonesia	IndoNLU Benchmark (12 tasks)	F1 rata-rata melampaui mBERT pada 12 task NLP Indonesia	Terbatas pada teks formal; performa lebih rendah pada teks informal/slang
Ridhwan & Hargreaves (2021)	Fine-tuned BERT untuk analisis sentimen ulasan aplikasi mobile	Google Play Store reviews (Inggris)	Akurasi 91% (3-class)	Tidak mencakup bahasa Indonesia; teks lebih formal
Abid et al. (2022)	TF-IDF + SVM vs BERT untuk sentimen Twitter Indonesia	Corpus Twitter Indonesia	BERT 78% vs TF-IDF+SVM 68% (F1)	Dataset Twitter; berbeda karakteristik dengan ulasan Play Store

Proyek ini memposisikan diri pada celah antara penelitian IndoBERT yang umumnya menggunakan dataset benchmark formal dan penerapan pada domain ulasan aplikasi mobile yang bersifat informal. Berbeda dengan penelitian sebelumnya, proyek ini secara spesifik mengaplikasikan IndoBERT pada ulasan Spotify berbahasa Indonesia dari Google Play Store dengan pendekatan balanced sampling dan label yang diturunkan dari rating pengguna, serta membandingkannya secara langsung dengan baseline TF-IDF + Logistic Regression dalam kondisi eksperimen yang terkontrol.

2.2 Landasan Teori Model yang Dipilih

IndoBERT merupakan implementasi arsitektur BERT (Bidirectional Encoder Representations from Transformers) yang di-pre-train khusus pada korpus bahasa Indonesia berskala besar. Arsitektur BERT terdiri atas beberapa komponen utama: lapisan embedding yang menggabungkan token embedding, segment embedding, dan positional embedding; tumpukan N lapisan Transformer Encoder (IndoBERT base menggunakan 12 lapisan); serta mekanisme Multi-Head Self-Attention sebagai inti dari setiap lapisan encoder.


Komponen kunci arsitektur Transformer adalah mekanisme Scaled Dot-Product Attention yang dirumuskan sebagai:

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k}) \cdot V \quad (2.1)$$

di mana Q adalah matriks query, K adalah matriks key, V adalah matriks value yang semuanya merupakan transformasi linear dari representasi input, dan d_k adalah dimensi ruang key yang digunakan sebagai faktor normalisasi untuk mencegah nilai dot product yang terlalu besar sebelum melewati fungsi softmax. Persamaan ini memungkinkan model untuk secara dinamis menentukan bobot perhatian antar token dalam sekuens input, sehingga mampu menangkap dependensi jarak jauh dalam teks.

Pada proyek ini, IndoBERT digunakan untuk sequence classification dengan menambahkan classification head berupa linear layer di atas representasi token [CLS], yang kemudian memprediksi distribusi probabilitas atas 3 kelas sentimen. Fine-tuning dilakukan dengan memperbarui seluruh parameter model termasuk lapisan classification head yang diinisialisasi secara acak.

Gambar 2.1: Arsitektur Transformer (Sumber: [1])



2.3 Justifikasi Ilmiah Pemilihan Pendekatan AI

(1) Alasan memilih Transformer/IndoBERT:

Pendekatan berbasis TF-IDF + Logistic Regression atau SVM memiliki keterbatasan fundamental dalam memahami konteks dan urutan kata. Misalnya, kalimat 'Aplikasinya tidak bagus' dan 'Tidak, aplikasinya bagus' memiliki distribusi kata yang sangat mirip tetapi makna berlawanan, TF-IDF tidak mampu membedakannya. LSTM dan GRU memproses sekuens secara berurutan sehingga mengalami degradasi untuk dependensi jarak jauh dan sulit diparalelkan. Transformer dengan self-attention mampu menangkap dependensi antara semua pasangan token secara simultan tanpa terbatas oleh jarak, menjadikannya superior untuk teks dengan konteks kompleks. IndoBERT secara khusus di-pre-train pada teks bahasa Indonesia sehingga memahami nuansa, slang, dan morfologi bahasa Indonesia jauh lebih baik dari model multilingual seperti mBERT.


(2) Tradeoff yang dipertimbangkan:

IndoBERT memiliki ~110 juta parameter, memerlukan GPU dan memori yang signifikan, serta durasi training lebih lama dibandingkan TF-IDF + LR. Namun, dengan dataset terbatas (2.100 sampel training), fine-tuning memanfaatkan pengetahuan yang sudah tertanam dari pre-training memungkinkan performa tinggi meski data relatif sedikit. TF-IDF + LR dipilih sebagai baseline karena sangat ringan, interpretable, dan cepat, sehingga menjadi pembanding yang adil untuk mengukur nilai tambah pendekatan deep learning.

(3) Keunggulan dalam konteks domain:


Ulasan aplikasi di Google Play Store sering menggunakan bahasa informal, singkatan, dan ekspresi kolokial bahasa Indonesia ('mantap', 'nge-bug', 'gak bisa dibuka', dll.). IndoBERT yang di-pre-train pada ~4 GB teks bahasa Indonesia mencakup teks informal sehingga lebih robust terhadap variasi linguistik ini dibandingkan model berbahasa Inggris atau pendekatan statistik murni.

2.4 Block Diagram Sistem End-to-End



Gambar 2.2: Block diagram sistem yang diusulkan

2.5 Flowchart Program



Gambar 2.3: Flowchart program training dan inference

BAB 3

IMPLEMENTASI & HASIL EKSPERIMEN

3.1 Dataset & Pra-pemrosesan

Dataset yang digunakan adalah Spotify Reviews Indonesia (Google Play Store) yang tersedia secara publik di Kaggle (<https://www.kaggle.com/datasets/pandaa12/spotify-reviews-indonesia-google-play-store>). Dataset ini berisi 100.000 ulasan pengguna aplikasi Spotify di Google Play Store dalam bahasa Indonesia, dengan kolom utama: Nama User, Ulasan (teks ulasan), Rating (nilai 1–5), Tanggal, Likes, dan Versi App. Dataset bersifat publik tanpa lisensi komersial yang membatasi penggunaan akademis.

Label sentimen dibuat secara otomatis dari nilai Rating menggunakan aturan pemetaan berikut: rating 1–2 = negatif (kelas 0), rating 3 = netral (kelas 1), rating 4–5 = positif (kelas 2). Distribusi asli dataset sangat tidak seimbang: positif 75.670 (77,2%), negatif 19.689 (20,1%), netral 4.641 (4,7%). Untuk mengatasi ketidakseimbangan ini, dilakukan balanced sampling sebanyak 4.000 data per kelas (total 12.000 sampel, random_state=42).

Pra-pemrosesan teks dilakukan secara ringan untuk mempertahankan konteks linguistik yang dibutuhkan IndoBERT: (1) konversi ke huruf kecil, (2) penghapusan URL, (3) penghapusan mention (@user), (4) penghapusan simbol hashtag (#), (5) penghapusan karakter khusus non-alphanumeric, dan (6) normalisasi spasi berlebih. Setelah cleaning, 2.031 dari 100.000 baris dihapus karena menghasilkan teks kosong.

Contoh sampel dari dataset setelah preprocessing:

1. Teks: 'aplikasinya bagus banget, lagu lengkap dan mudah digunakan' | Rating: 5 | Sentimen: positif
2. Teks: 'sering error dan lag, padahal sudah premium' | Rating: 1 | Sentimen: negatif
3. Teks: 'lumayan sih tapi iklannya terlalu banyak' | Rating: 3 | Sentimen: netral

Tabel 3.1: Pembagian dataset

Subset	Jumlah Sampel	Rasio (%)
Training	8.400	70%
Validation	1.800	15%
Test	1.800	15%
Total	12.000	100%

Setiap subset memiliki distribusi kelas yang seimbang (2.800/600/600 per kelas untuk train/val/test masing-masing) berkat penggunaan parameter stratify pada proses split. Random seed 42 digunakan secara konsisten di seluruh proses sampling dan splitting.

3.2 Konfigurasi Eksperimen

Parameter dalam proyek kali ini ditunjukkan pada Tabel 3.2

Tabel 3.2: Hyperparameter eksperimen

Hyperparameter	Nilai
Model utama	indobenchmark/indobert-base-p1
Learning rate (Run 1 - Main)	2e-5
Learning rate (Run 2 - Tuned)	1e-5
Batch size	8
Epoch	3
Optimizer	AdamW
Weight decay	0.01
Scheduler	Default HuggingFace (linear warmup)
Loss function	Cross-Entropy Loss
Max token length	128
Eval strategy	Per epoch
Metric for best model	F1-Macro
Random seed	42
Hardware	GPU (Tesla T4 via Google Colab)
Framework	PyTorch + HuggingFace Transformers
Baseline: TF-IDF fitur	10.000 (unigram + bigram)
Baseline: Classifier	Logistic Regression (max_iter=1000, class_weight=balanced)

3.3 Metrik Evaluasi

Metrik utama yang digunakan adalah F1-Macro dan Accuracy. F1-Macro dipilih sebagai metrik utama karena menghitung rata-rata nilai F1 setiap kelas secara tidak terbobot sehingga kinerja pada kelas minoritas (khususnya netral) mendapat perhatian yang sama dengan kelas mayoritas. Hal ini penting mengingat balanced sampling yang dilakukan tidak menjamin bahwa model belajar sama baiknya untuk semua kelas.

Accuracy digunakan sebagai metrik pendukung untuk memberikan gambaran keseluruhan performa model. Selain itu, Precision-Macro dan Recall-Macro dilaporkan untuk memberikan gambaran tradeoff antara presisi dan sensitivitas per kelas. Untuk analisis lebih mendalam, classification report per kelas (precision, recall, F1 untuk negatif, netral, dan positif) dan confusion matrix juga disajikan.

3.4 Hasil Kuantitatif

Tabel 3.3: Hasil kuantitatif model

Konfigurasi	Accuracy	Precision	Recall	F1-Macro
TF-IDF + Logistic Regression (Baseline)	65,5%	64,85%	65,5%	65,09%
IndoBERT LR=2e-5, Epoch=3 (Main)	67,89%	67,45%	67,89%	67,59%
IndoBERT LR=1e-5, Epoch=3 (Tuned)	67,94%	67,37%	67,94%	67,58%

Perincian hasil per kelas untuk model terbaik (IndoBERT LR=2e-5):

Kelas	Precision	Recall	F1-Score	Support
negatif	0.67	0.63	0.65	600
netral	0.57	0,55	0,56	600
positif	0,78	0,85	0,82	600


3.5 Analisis Hyperparameter Tuning

Tuning dilakukan secara manual (manual search) dengan memvariasikan satu hyperparameter kunci, yaitu learning rate, sambil mempertahankan epoch (3) dan batch size (8) tetap. Dua konfigurasi yang dibandingkan adalah: Run 1 (Main) dengan LR=2e-5, dan Run 2 (Tuned) dengan LR=1e-5.

Hasil menunjukkan bahwa $LR=2e-5$ memberikan performa yang lebih baik pada F1-Macro (67,59% vs 67,58%) dan Precision-Macro (67,45% vs 67,37%). Namun, dari segi Accuracy (67,89% vs 67,94%) dan Recall-Macro (67,89% vs 67,94%), konfigurasi $LR=1e-5$ memberikan hasil yang sedikit lebih unggul. Perbedaan di antara kedua model IndoBERT ini sangat tipis (di bawah 0,1 poin persentase), menunjukkan bahwa kedua nilai learning rate tersebut berada dalam rentang optimal untuk konvergensi model pada dataset ini dalam jumlah 3 epoch.

Jika dibandingkan dengan baseline TF-IDF + Logistic Regression (Accuracy: 65,50% dan F1-Macro: 65,09%), kedua model berbasis IndoBERT memberikan peningkatan performa yang signifikan, yaitu sekitar 2,4 hingga 2,5 poin persentase pada metrik akurasi dan F1-Macro.

Hyperparameter yang paling sensitif dalam eksperimen ini adalah learning rate. LR yang terlalu tinggi berisiko menyebabkan catastrophic forgetting pada bobot pre-trained, sementara LR yang terlalu rendah memperlambat adaptasi pada tugas downstream. Rentang $LR=1e-5$ hingga $2e-5$ merupakan nilai yang direkomendasikan oleh paper BERT orisinal untuk fine-tuning dan terbukti konsisten memberikan performa terbaik dalam eksperimen ini.



Gambar 3.1: Perbandingan performa semua model (Accuracy & F1-Macro)

3.6 Hasil Kualitatif & *Error Analysis*

Dari 1.800 data test, model IndoBERT terbaik ($LR=2e-5$) menghasilkan 578 prediksi yang salah (32,1% error rate). Pola kesalahan berdasarkan confusion matrix:

Dari kelas negatif (600 sampel): 187 diprediksi sebagai netral, 34 diprediksi sebagai positif.

Dari kelas netral (600 sampel): 163 diprediksi sebagai negatif, 107 diprediksi sebagai positif.

Dari kelas positif (600 sampel): 21 diprediksi sebagai negatif, 66 diprediksi sebagai netral.

Kelas netral adalah sumber kesalahan terbesar 163 ulasan netral salah diprediksi sebagai negatif. Berikut contoh kasus kesalahan:


Kasus Salah 1: Teks: 'iklan kurangi' | Rating: 3 | True: netral | Pred: negatif. Hipotesis: Kata 'iklan' yang berkonotasi negatif dominan mempengaruhi prediksi, meskipun kalimatnya sangat pendek dan ambigu.

Kasus Salah 2: Teks: 'senang karena banyak lagu lagu nya' | Rating: 3 | True: netral | Pred: positif. Hipotesis: Konten teks mengandung ekspresi positif ('senang', 'banyak lagu') namun rating pengguna hanya 3, menunjukkan inkonsistensi antara teks dan rating yang menjadi label.


Kasus Salah 3: Teks: 'sering mengalami iklan tetapi blackscreen gabisa skip...' | Rating: 1 | True: negatif | Pred: netral. Hipotesis: Kalimat panjang dengan konteks yang kompleks meskipun mengandung keluhan, tidak ada kata negatif yang sangat eksplisit sehingga model kesulitan mengklasifikasikannya.

Kasus Salah 4: Teks: 'ship' | Rating: 5 | True: positif | Pred: negatif. Hipotesis: Teks sangat pendek (satu kata) tanpa konteks, model tidak memiliki cukup informasi untuk mengklasifikasikan dengan benar.


Kasus Salah 5: Teks: 'boleh tahan' | Rating: 5 | True: positif | Pred: netral. Hipotesis: Ekspresi kolokial 'boleh tahan' yang bermakna positif dalam bahasa informal Indonesia tidak terrepresentasikan dengan baik dalam corpus pre-training IndoBERT yang lebih formal.



Gambar 3.2: Confusion matrix Baseline TF-IDF + Logistic Regression



Gambar 3.3: Confusion matrix IndoBERT terbaik (LR=2e-5, Epoch=3)



Gambar 3.4: Distribusi sentimen dataset Spotify Reviews Indonesia

3.7 Pembahasan

RM1: IndoBERT(2e-5) secara konsisten mengungguli baseline TF-IDF + Logistic Regression. F1-Macro IndoBERT (67,59%) lebih tinggi 2,50 poin persentase dibandingkan baseline (65,09%), dan Accuracy-nya lebih tinggi 2,39 poin (67,89% vs 65,50%). Perbedaan ini signifikan secara praktis, meskipun dengan 12.000 sampel yang terbatas. Keunggulan IndoBERT paling terlihat pada kelas positif (F1 0,82 vs 0,80 pada baseline) dan kelas negatif (F1 0,65 vs 0,64 pada baseline).

RM2: Perbedaan learning rate (2e-5 vs 1e-5) menghasilkan perbedaan performa yang kecil (~0,02 poin F1-Macro). LR=2e-5 terbukti lebih optimal, konsisten dengan rekomendasi paper BERT. Dalam konteks dataset kecil (8.400 sampel), LR yang terlalu kecil menyebabkan model belum sepenuhnya mengadaptasi pengetahuan pre-trained pada tugas spesifik dalam 3 epoch.

RM3: Kelas netral secara konsisten menjadi kelas paling sulit dengan F1 0,56 (IndoBERT) dan 0,52 (baseline). Penyebab utama: (a) ulasan rating 3 seringkali mengandung campuran sentimen positif dan negatif ('bagus, tapi sering iklan'); (b) inkonsistensi antara isi teks dan nilai rating pengguna, ulasan rating 3 bisa berisi keluhan atau pujian; (c) fitur linguistik kelas netral overlapping dengan kedua kelas lainnya.

Dibandingkan dengan literatur, performa IndoBERT pada dataset ini (F1-Macro 67,59%) berada di bawah hasil penelitian Ridhwan & Hargreaves (2021) yang mencapai 91% akurasi pada ulasan aplikasi berbahasa Inggris. Perbedaan ini wajar mengingat: (1) dataset bahasa Indonesia mengandung lebih banyak informal language dan slang; (2) label diturunkan dari rating, bukan anotasi manual yang lebih akurat; (3) jumlah data yang digunakan jauh lebih sedikit (8.400 vs dataset lebih besar pada penelitian tersebut).

Keterbatasan eksperimen: (1) label sentimen diturunkan dari rating sehingga ada noise pada kelas netral; (2) balanced sampling mereduksi ukuran dataset dari 100.000 menjadi 12.000; (3) hanya dua konfigurasi learning rate yang dibandingkan; (4) tidak dilakukan multiple seed untuk mengukur variance hasil.

BAB 4

PEMBAGIAN TUGAS & DEKLARASI KONTRIBUSI INDIVIDUAL

4.1 Dhafin Hamizan Setiawan – NPM. 2306267145

IV.1.1 Komponen yang Dikerjakan

Daftar konkret bagian proyek yang menjadi tanggung jawab penuh saya:

- **Kode/modul:** notebooks/03_transformer.ipynb (meliputi proses tokenisasi teks dengan WordPiece, konfigurasi hyperparameter pelatihan, proses fine-tuning model IndoBERT menggunakan PyTorch/Hugging Face, serta evaluasi performa akhir).
- **Bagian arsitektur:** Implementasi arsitektur berbasis Self-Attention menggunakan model bahasa pra-latih (pre-trained) IndoBERT untuk menangkap representasi semantik teks yang mendalam.
- **Bagian analisis:** Analisis mendalam Confusion Matrix kedua model, kalkulasi F1-macro untuk data multi-kelas, serta Error Analysis untuk mengidentifikasi bias dan limitasi model IndoBERT dalam mengenali teks ulasan yang ambigu/sarkasme pada aplikasi Spotify.
- **Bagian laporan:** Bab 3.5 (Analisis *Hyperparameter Tuning*) dan Bab 3.6 (Hasil Kualitatif & *Error Analysis*)

IV.1.2 Pernyataan Penggunaan AI Assistant

- **Tool yang dipakai:** GPT Go dan GitHub Copilot.
- **Untuk bagian apa:** Autocompletion penulisan argumen pada Hugging Face TrainingArguments, debugging kendala data type mismatch pada PyTorch tensor saat dikirim ke GPU, dan referensi matematis rumus scaled dot-product attention.
- **Tingkat ketergantungan:** Sedang (estimasi ~50% output berasal dari AI)
- **Pernyataan:** Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

4.2 Dimas Ananda Sutiardi – NPM. 2306250586

IV.2.1 Komponen yang Dikerjakan

- **Kode/modul:** *notebooks/02_baseline.ipynb* (meliputi pembentukan matriks TF-IDF dari teks ulasan, pelatihan model *LogisticRegression* multi-kelas, evaluasi metrik dasar, dan penyimpanan model ke format *.pkl*).
- **Bagian arsitektur:** Implementasi ekstraksi fitur statistik konvensional (TF-IDF) dan klasifikasi linear sebagai standar tolok ukur (baseline) performa awal.
- **Bagian analisis:** Analisis keterbatasan pembobotan statistik (TF-IDF) dalam menangkap dependensi urutan kata (word order) serta evaluasi performa awal model linear pada data ulasan yang tidak seimbang.
- **Bagian laporan:** Bab 2 (Pendekatan AI), Bab 3.3 (Metrik Evaluasi) dan Bab 3.4 (Hasil Kuantitatif)

IV.2.2 Pernyataan Penggunaan AI Assistant

- **Tool yang dipakai:** GPT Go dan GitHub Copilot.
- **Untuk bagian apa:** *Eksplorasi sintaks penyesuaian parameter multi-kelas (multi_class='multinomial') pada Scikit-learn Logistic Regression dan optimalisasi parameter tokenizer TF-IDF untuk unigram/bigram.*
- **Tingkat ketergantungan:** Sedang (estimasi ~50% output berasal dari AI)
- **Pernyataan:** Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

4.3 Daffa Bagus Dhiananto – NPM. 2306250756

IV.3.1 Komponen yang Dikerjakan

- **Kode/modul:** *notebooks/01_eda_preprocessing.ipynb* dan *src/preprocessing.py* (meliputi seluruh fungsi text cleaning, penanganan class imbalance / dataset balancing, serta train-validation-test split).
- **Bagian arsitektur:** Integrasi pustaka pemrosesan data, pipeline pembersihan teks (preprocessing), penanganan ketidakseimbangan kelas (class imbalance), dan skema pembagian data terstratifikasi.

- **Bagian analisis:** Analisis karakteristik data mentah (Exploratory Data Analysis), distribusi label sentimen aplikasi Spotify, dan dampak pra-pemrosesan teks berbasis regular expression (regex) terhadap kebersihan data.
- **Bagian laporan:** Bab 3.1 (Dataset & Pra-pemrosesan), Bab 3.2 (Konfigurasi Eksperimen), dan Bab 5.1 (Kesimpulan)

IV.3.2 Pernyataan Penggunaan *AI Assistant*

- **Tool yang dipakai:** GPT Go dan GitHub Copilot.
- **Untuk bagian apa:** Pembuatan pola Regular Expression (regex) untuk membersihkan karakter khusus/emoji pada ulasan Play Store dan debugging saat proses manipulasi matriks dengan Pandas
- **Tingkat ketergantungan:** Sedang (estimasi ~50% output berasal dari AI)
- **Pernyataan:** Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

4.4 Rafi Naufal Aryaputra – NPM. 2306250680

IV.3.1 Komponen yang Dikerjakan

- **Kode/modul:** notebooks/04_web_demo.ipynb (meliputi instalasi Gradio, pemuatan saved model/tokenizer dari folder lokal, konfigurasi device GPU/CPU, dan peluncuran URL demo).
- **Bagian arsitektur:** Implementasi antarmuka interaktif berbasis web untuk inferensi model secara real-time menggunakan Gradio.
- **Bagian analisis:** Evaluasi fungsionalitas antarmuka web dalam memproses berbagai variasi input ulasan secara langsung (real-time inference) serta analisis sederhana terhadap kecocokan hasil prediksi sentimen yang dikeluarkan oleh model Gradio.
- **Bagian laporan:** Bab 1 (Pendahuluan), Bab 3.7 (Pembahasan), dan 5.3 (Pekerjaan Lanjutan / Future Work)

IV.3.2 Pernyataan Penggunaan AI Assistant

- **Tool yang dipakai:** Gemini dan GitHub Copilot.
- **Untuk bagian apa:** Langkah-langkah pembuatan serta syntax2 untuk pembuatan web demo dengan gradio
- **Tingkat ketergantungan:** Sedang (estimasi ~50% output berasal dari AI)
- **Pernyataan:** Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

BAB 5

KESIMPULAN & PEKERJAAN LANJUTAN

5.1 Kesimpulan

1. IndoBERT (LR=2e-5, batch size=8, epoch=3) mencapai akurasi 67,89% dan F1-Macro 67,59% pada test set, mengungguli baseline TF-IDF + Logistic Regression (akurasi 65,50%, F1-Macro 65,09%) sebesar 2,39 dan 2,50 poin persentase masing-masing. Hal ini menjawab RM1 bahwa Transformer berbasis IndoBERT mampu mengklasifikasikan sentimen ulasan Spotify berbahasa Indonesia lebih baik dibandingkan pendekatan statistik klasik (lihat Tabel 3.3).
2. Perbandingan dua konfigurasi learning rate menunjukkan LR=2e-5 lebih optimal dari LR=1e-5 dengan selisih F1-Macro 0,02 poin (67,59% vs 67,58%), menjawab RM2. Perbedaan kecil ini mengindikasikan bahwa dalam 3 epoch, learning rate yang lebih tinggi memberikan adaptasi lebih cepat tanpa menyebabkan catastrophic forgetting yang signifikan pada dataset berukuran 1.800 sampel (lihat Subbab 3.5).
3. Kelas netral merupakan kelas paling sulit diprediksi dengan F1-Score 0,56 pada model IndoBERT terbaik, dibandingkan F1 0,65 (negatif) dan 0,82 (positif). Error analysis pada 578 prediksi salah menunjukkan 187 ulasan netral gagal diprediksi sebagai negatif, terutama akibat inkonsistensi antara isi teks dan nilai rating pengguna serta ambiguitas linguistik pada ulasan pendek, menjawab RM3 (lihat Subbab 3.6).

5.2 Klaim Bonus Skor

- ☒ **B1. Evaluasi Komparatif & Iterasi:** tiga konfigurasi dibandingkan (Baseline, IndoBERT LR=2e-5, IndoBERT LR=1e-5) → bukti pada Subbab 3.4 dan 3.5
- ☐ **B2. Dataset Mandiri:** → tidak diklaim (dataset dari Kaggle)
- ☒ **B3. Analisis Etika, Bias, & Keterbatasan:** → inkonsistensi label berbasis rating, bias kelas netral, keterbatasan teks informal → bukti pada Subbab 3.7

5.3 Pekerjaan Lanjutan (*Future Work*)

1. Mengevaluasi model pada dataset ulasan aplikasi lain (misalnya Tokopedia, Gojek) untuk mengukur generalisasi out-of-domain IndoBERT terhadap domain ulasan berbahasa Indonesia yang berbeda.
2. Mengganti backbone dengan IndoBERT-large atau XLM-RoBERTa base untuk mengukur apakah model yang lebih besar memberikan peningkatan signifikan pada dataset ulasan informal berukuran terbatas.
3. Menerapkan anotasi label sentimen secara manual oleh tim untuk menggantikan pelabelan berbasis rating, guna mengurangi noise pada kelas netral dan meningkatkan kualitas data training.
4. Menambahkan modul interpretability berbasis attention weight visualization atau Integrated Gradients untuk memahami token mana yang paling berpengaruh terhadap prediksi sentimen, terutama pada kasus-kasus yang salah prediksi.
5. Melakukan eksperimen dengan jumlah epoch yang lebih besar (5–10 epoch) serta teknik early stopping berbasis F1-Macro untuk menemukan titik optimal konvergensi model pada dataset ini.

DAFTAR PUSTAKA

- [1] "File:The-Transformer-model-architecture.png - Wikimedia Commons," Wikimedia.org, Dec. 2019. <https://commons.wikimedia.org/wiki/File:The-Transformer-model-architecture.png>
- [2] B. Wilie, K. Vincentio, G. I. Winata, S. Cahyawijaya, X. Li, Z. Y. Lim, S. Soleman, R. Mahendra, P. Fung, S. Bahar, and A. Purwarianti, "IndoNLU: Benchmark and Resources for Evaluating Indonesian Natural Language Understanding," in Proceedings of AACL-IJCNLP 2020, pp. 843–857, 2020.
- [3] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention Is All You Need," in Advances in Neural Information Processing Systems (NeurIPS), vol. 30, 2017.
- [4] Pandaa12, Spotify Reviews - Indonesia (Google Play Store), Kaggle Dataset, <https://www.kaggle.com/datasets/pandaa12/spotify-reviews-indonesia-google-play-store> , 2024.
- [5] "IndoBERT," Share.google, 2017. <https://share.google/vsWh9jjWfr92MY6aV> (accessed May 25, 2026).

LAMPIRAN A

Berkas Metadata Proyek (JSON)

```
{
  "kode_kelompok": "K13",
  "topik_pilihan": 4,
  "nama_topik": "Transformer",
  "judul_proyek": "Klasifikasi Sentimen Ulasan Spotify Menggunakan IndoBERT Berbasis Transformer",
  "sub_judul_proyek": "Analisis Sentimen Teks Bahasa Indonesia / IndoBERT (Transformer)",
  "abstrak_singkat": "Penelitian ini menerapkan fine-tuning pada model IndoBERT yang berbasis arsitektur Transformer untuk mengklasifikasikan sentimen ulasan aplikasi Spotify pada Google Play Store ke dalam tiga kelas: negatif, netral, dan positif. Dataset berasal dari Kaggle, berisi 100.000 ulasan pengguna dalam bahasa Indonesia yang kemudian jika diseimbangkan menjadi subset 12.000 sampel (4.000 data per kelas) dengan pembagian data 70/15/15. Model utama IndoBERT dibandingkan dengan baseline TF-IDF + Logistic Regression. Hasil pengujian menunjukkan model utama IndoBERT (LR=2e-5) meraih akurasi 67,89% dan F1-Macro 67,59%, melampaui baseline yang memperoleh akurasi 65,5% dan F1-Macro 65,09%. Kelas netral terbukti menjadi kelas yang paling sulit diklasifikasikan dengan F1-score 0,56 karena adanya ambiguitas teks.",
  "datasets": [
    {
      "nama": "Spotify Reviews - Indonesia (Google Play Store)",
      "tipe": "publik",
      "sumber": "Kaggle",
      "url_sumber_publik": "https://www.kaggle.com/datasets/pandaa12/spotify-reviews-indonesia-google-play-store",
      "jumlah_sampel_asli": 100100,
      "jumlah_sampel_digunakan": 12000,
      "jumlah_kelas": 3,
      "proses_akuisisi_mandiri": "",
      "peran_di_proyek": "Dataset utama untuk training (8.400 sampel), validasi (1.800 sampel), dan testing (1.800 sampel) setelah dilakukan balanced sampling (4.000 sampel per kelas).",
      "spek_rl": null
    }
  ],
  "metrik_utama": [
    "Accuracy",
    "Precision-Macro",
    "Recall-Macro",
    "F1-Macro",
    "Confusion Matrix"
  ],
  "hasil_eksperimen": {
    "baseline_tf_idf_logistic_regression": {
      "accuracy": 0.6550,
      "precision": 0.6485,
      "recall": 0.6550,
      "f1_macro": 0.6509
    },
    "indobert_lr_2e_5_main": {
      "accuracy": 0.6789,
      "precision": 0.6758,
      "recall": 0.6789,
      "f1_macro": 0.6759
    },
    "indobert_lr_1e_5_tuned": {
      "accuracy": 0.6794,
      "precision": 0.6737,
```

```

"recall": 0.6794,
"f1_macro": 0.6758
},
},
"kontribusi_anggota": [
{
"nama": "Dhafin Hamizan Setiawan",
"npm": "2306267145",
"peran_utama": "Transformer & Deep Learning Specialist",
"focus_area": [
"Proses tokenisasi teks dengan menggunakan metode WordPiece",
"Konfigurasi hyperparameter pelatihan dan proses fine-tuning model IndoBERT via PyTorch dan Hugging Face",
"Analisis mendalam Confusion Matrix dan kalkulasi metrik F1-macro multi-kelas",
"Pelaksanaan Error Analysis untuk mengidentifikasi bias serta limitasi model IndoBERT pada ulasan yang ambigu atau sarkasme"
],
"konsep_dikuasai_implementasi": [
"PyTorch & Hugging Face Transformers API",
"WordPiece Tokenization pipeline",
"Confusion Matrix calculation",
"Multi-class F1-macro evaluation matrices"
],
"konsep_dikuasai_teoris": [
"Self-Attention mechanism",
"Pre-trained language models architecture",
"Error analysis methodology dalam domain NLP",
"Transformers optimization and training dynamics"
],
"bagian_laporan": [
"Bab III.5 (Analisis Hyperparameter Tuning)",
"Bab III.6 (Hasil Kualitatif & Error Analysis)"
],
"bagian_kode": [
"notebooks/03_transformer.ipynb"
]
},
{
"nama": "Dimas Ananda Sutiardi",
"npm": "2306250586",
"peran_utama": "Baseline & Evaluation Engineer",
"focus_area": [
"Pembentukan matriks pembobotan statistik TF-IDF dari korpus teks ulasan",
"Pelatihan model linear Logistic Regression multi-kelas serta evaluasi metrik dasar",
"Penyimpanan berkas model ke format serialisasi .pkl",
"Analisis keterbatasan metode statistik konvensional dalam menangkap dependensi urutan kata (word order)"
],
"konsep_dikuasai_implementasi": [
"TF-IDF Vectorization menggunakan Scikit-Learn",
"Multi-class Logistic Regression training",
"Model serialization and persistence (.pkl)",
"Baseline evaluation metrics extraction"
],
"konsep_dikuasai_teoris": [
"Statistical feature extraction in text",
"Linear classification models algorithms",
"Word order dependency limitations of statistical NLP",
"Performance benchmarks criteria"
],
"bagian_laporan": [

```

```

    "Bab II (Pendekatan AI)",
    "Bab III.3 (Metrik Evaluasi)",
    "Bab III.4 (Hasil Kuantitatif)"
  ],
  "bagian_kode": [
    "notebooks/02_baseline.ipynb"
  ]
},
{
  "nama": "Daffa Bagus Dhiananto",
  "npm": "2306250756",
  "peran_utama": "Data Explorer & Preprocessing Analyst",
  "focus_area": [
    "Exploratory Data Analysis (EDA) untuk meninjau karakteristik data mentah",
    "Analisis distribusi persebaran label sentimen pada ulasan aplikasi Spotify",
    "Pembersihan teks korpus bahasa Indonesia berbasis regular expression (regex) terhadap kebersihan data"
  ],
  "konsep_dikuasai_implementasi": [
    "Regular Expression (regex) text cleaning operations",
    "Pandas data matrix manipulation & debugging structures",
    "Data visualization techniques for label distribution"
  ],
  "konsep_dikuasai_teor": [
    "Exploratory Data Analysis core concepts",
    "Text preprocessing and normalization data pipelines",
    "Impact of noisy text data in Natural Language Processing"
  ],
  "bagian_laporan": [
    "Bab III.1 (Dataset & Pra-pemrosesan)",
    "Bab III.2 (Konfigurasi Eksperimen)",
    "Bab V.1 (Kesimpulan)"
  ],
  "bagian_kode": [
    "notebooks/01_eda_preprocessing.ipynb" dan "src/preprocessing.py"
  ]
},
{
  "nama": "Rafi Naufal Aryaputra",
  "npm": "2306250680",
  "peran_utama": "Deployment & Interface Engineer",
  "focus_area": [
    "Instalasi, konfigurasi, dan setup framework Gradio untuk web demo",
    "Pemuatan saved model biner dan tokenizer IndoBERT dari folder penyimpanan lokal",
    "Penyusunan fungsi inferensi pipeline data real-time untuk pemrosesan teks input baru",
    "Perancangan antarmuka visual interaktif untuk demonstrasi model aplikasi secara langsung"
  ],
  "konsep_dikuasai_implementasi": [
    "Gradio UI framework development",
    "Local model loading and state pipeline integration",
    "Interactive web application layout customization"
  ],
  "konsep_dikuasai_teor": [
    "Model deployment architectures for local development",
    "User Interface design patterns for AI applications",
    "Real-time text inference processing workflows"
  ],
  "bagian_laporan": [
    "Bab I (Pendahuluan / Latar Belakang Proyek)",
    "Bab III.7 (Kontribusi Individual & Deklarasi AI)",
    "Bab V.3 (Pekerjaan Lanjutan / Future Work)"
  ],
}

```



```

    "bagian_kode": [
        "notebooks/04_web_demo.ipynb"
    ]
},
"tautan": {
    "github": "https://github.com/Dimassutiardi/Proyek-Akhir-AI",
    "colab": "https://colab.research.google.com/drive/1Akavgv126wsKYRrn0jWM5fEEVzYP0YQl?usp=sharing",
    "dataset_mandiri": "https://www.kaggle.com/datasets/pandaa12/spotify-reviews-indonesia-google-play-store",
    "video_demo": null
},
"ai_assistant_usage": {
    "digunakan": true,
    "tools": [
        "GPT Go",
        "GitHub Copilot",
        "Gemini"
    ],
    "bagian": [
        "Pembuatan pola Regular Expression (regex) untuk text cleaning",
        "Eksplorasi sintaks penyesuaian parameter multinomial pada Scikit-learn",
        "Kustomisasi visualisasi Confusion Matrix menggunakan Seaborn/Matplotlib",
        "Debugging fungsi ekstraksi sampel ulasan yang salah diklasifikasikan (false predictions)"
    ],
    "estimasi_persentase": 20
}
}

```

LAMPIRAN B

Tautan Repositori & Dataset

GitHub repo: <https://github.com/Dimassutiardi/Proyek-Akhir-AI>

Google Colab:
<https://colab.research.google.com/drive/1Akavgv126wsKYRrn0jWM5fEEVzYP0YQ1?usp=sharing>

Dataset mandiri:
<https://www.kaggle.com/datasets/pandaa12/spotify-reviews-indonesia-google-play-store?resource=download>

Video demo:
https://emas3.ui.ac.id/pluginfile.php/5246602/assignsubmission_file/submission_files/11144547/ProyekAkhir_Transformer_Kelompok13.mp4.mp4?forcedownload=1

Status akses: repositori publik / Colab dengan permission “anyone with the link can view”. Sudah diverifikasi terbuka pada 25 Mei 2026.

APPENDIX C

Research Participation Consent Form (*Informed Consent*)

C.1 Brief Explanation. *Research:* Development & validation of an *agentic AI* framework for supporting academic oral examinations. *Principal investigator:* [Name of course lecturer], Department of Computer Engineering, Universitas Indonesia. *Co-investigator:* a final-year undergraduate student supervised by the principal investigator. *Contact:* [principal investigator's email]. *Ethics review status:* **under review**. *Context:* data collection is conducted alongside the oral examination of the AI course's final assessment. The oral examination is held as part of the academic assessment regardless of the participant's research-participation choice.

C.2 Data Collected. Final report (PDF) and `metadata.json` file; audio and video recordings of the oral examination; automatic transcripts derived from those recordings; lecturer's *judgment* scores (*ground truth*) and AI system's *judgment* scores (test variable). **Not collected:** biometric data other than voice/face, or personal data beyond what is contained in the academic report.

C.3 Data Management. Participant names and student IDs (NPMs) will be stored anonymously — replaced with participant codes (P001, P002, ...) prior to analysis. The code-to-identity mapping table is stored separately, encrypted, and accessed only by the principal investigator. Publications (journal articles, conference papers, theses) will not contain individual identities. Data is stored with encryption on infrastructure managed by the research team; retention is 5 years after the research concludes, after which the data is permanently deleted. Access is limited to the principal and co-investigators; no third party may access without an amendment to this *consent*.

C.4 Participant Rights. (1) The right to decline participation without affecting the course grade. (2) The right to partial participation (e.g. report/metadata may be used, video recording may not). (3) The right to withdraw data at any time **until 30 June 2026** by emailing the principal investigator with the subject [Withdrawal] - [Name] - [NPM]; confirmation of deletion is provided within ≤ 7 working days. After 30 June 2026 the data will have entered the analysis phase and withdrawal becomes impractical. (4) The right to ask questions at any time to the principal investigator. (5) The right to receive a summary of the research findings once they are published (sent to the registered email).

C.5 Individual Consent. Each member completes their personal block on the following pages — one page per member. Tick **exactly one** of the three options (A / B / C), then sign with a wet signature or an *e-signature*.

Individual Consent — Member 1

Full name : Dhafin Hamizan Setiawan
Student ID (NPM) : 2306267145
Email : dhafin.hs@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☐ **Option A — Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.

Participant's signature



25 Mei 2026

Witness / researcher's signature

Date:

Individual Consent — Member 2

Full name : Dimas Ananda Sutiardi
Student ID (NPM) : 23062508586
Email : dimassutiardi04@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☐ **Option A — Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.

Participant's signature



25 Mei 2026

Witness / researcher's signature

Date:

Individual Consent — Member 3

Full name : Daffa Bagus Dhiananto
Student ID (NPM) : 2306250756
Email : bagus.daffa20@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☐ **Option A — Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.

Participant's signature



25 Mei 2026

Witness / researcher's signature

Date

Individual Consent — Member 4

Full name : Rafi Naufal Aryaputra
Student ID (NPM) : 2306250680
Email : rafinaufal408@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☐ **Option A — Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.

Participant's signature



25 Mei 2026

Witness / researcher's signature

Date: